# Análisis Exploratorio y Detección de Riesgo

## Caso de Clasificación: Incumplimiento de Tarjetas de Crédito

Juan Camilo Ramirez Diaz

15 de abril de 2026

Matemáticas — Universidad de Antioquia

# Contexto y Definición

# Contexto del Conjunto de Datos

El proyecto se fundamenta en el análisis de riesgo crediticio basado en el comportamiento histórico de clientes bancarios.

- **Nombre:** *Default of Credit Card Clients Dataset*.
- **Fuente:** Repositorio de Machine Learning de UCI (Taiwán).
- **Periodo de captura:** Datos recolectados entre **abril de 2005** y **septiembre de 2005**.
- **Objetivo:** Predecir el incumplimiento de pago (*default*) en el mes siguiente (octubre).
- **Volumen:** 30,000 observaciones con 24 variables predictoras.

# El Problema: Riesgo e Incumplimiento

Para entender la dinámica de los datos, es fundamental definir qué significa el *default* y cómo impacta a la entidad financiera.

**Definición de Default**

Un cliente entra en incumplimiento cuando no logra realizar el pago mínimo exigido de su obligación crediticia en la fecha límite establecida.

- **Costo del Falso Negativo:** Clasificar como "solvente" a un cliente que incumple genera pérdidas directas de capital para el banco.
- **Costo del Falso Positivo:** Clasificar como "riesgoso" a un cliente bueno genera pérdida de costo de oportunidad y fricción comercial.
- **Desbalance Natural:** En la muestra estudiada, solo el **22.12 %** de los clientes presentan incumplimiento real.

# Dimensiones Críticas del Análisis

Se detallan las variables de mayor peso estadístico y aporte informativo identificadas en el EDA:

| Variable | Descripción | Naturaleza |
|---|---|---|
| default_payment | Indicador de incumplimiento (1 = Sí, 0 = No). | Cat. Binaria (Target |
| LIMIT_BAL | Límite de crédito otorgado al cliente. | Num. Continua |
| PAY_1 a PAY_6 | Historial de estado de mora (ej. 1 = retraso 1 mes). | Num. Ordinal |
| BILL_AMT1 | Monto de la factura en el mes más reciente. | Num. Continua |
| PAY_AMT1 | Monto del abono realizado en el mes anterior. | Num. Continua |
| EDUCATION | Nivel educativo (Posgrado, Universidad, Bachillerato). | Cat. Ordinal |
| AGE | Edad del titular de la cuenta en años. | Num. Continua |

**Variables adicionales analizadas:** *SEX, MARRIAGE, BILL_AMT2 a BILL_AMT6, PAY_AMT2 a PAY_AMT6.*

# Hipótesis de Estudio

**El pasado dicta el futuro**

Las características demográficas proveen contexto, pero el historial transaccional reciente es el verdadero "pulso" de la salud financiera del cliente.

1. **Historial reciente:** El estado de pago del mes más reciente (`PAY_1`) tendrá un peso predictivo significativamente superior al de los meses antiguos, siendo el mejor indicador de riesgo inmediato.
2. **Límite vs. Riesgo:** Existe una relación inversa entre el límite de crédito (`LIMIT_BAL`) y el default; clientes con límites más altos tienden a presentar mayor estabilidad financiera.
3. **Comportamiento vs. Demografía:** Las variables de conducta financiera superarán en importancia a las demográficas (edad, sexo, educación) para determinar la frontera de decisión.
4. **Carga financiera relativa:** El riesgo no depende solo del monto de la deuda (`BILL_AMT`), sino de su proporción respecto al límite disponible; una alta utilización incrementa el incumplimiento.

# Gestión de Datos y Extracción

# De los datos crudos a la base de datos

Antes de iniciar el análisis estadístico, consolidamos la información en un motor de bases de datos relacional para estructurar las consultas.

- **El camino:** Los datos transaccionales se migraron de un archivo `CSV` a una base de datos `SQLite` local (`credit_data.db`).
- **Organización:** Se generó la tabla `credit_default`, asegurando que variables financieras (montos) y ordinales (estados de pago) tuvieran la tipología correcta para evitar errores de cálculo en agregaciones.
- **Resultado:** Un entorno estructurado que permite extraer métricas de riesgo y agrupaciones a través de consultas SQL puras antes del análisis en Python.

# Ajustes iniciales y estructuración

**Cuadro 1:** Variables tratadas en la extracción

| Variable | Acción | Justificación |
|---|---|---|
| `ID` | Removida | Es un identificador de fila que no aporta valor predictivo al modelo. |
| `PAY_0` | Renombrada | Se ajustó a `PAY_1` para mantener la coherencia numérica con el resto del historial (hasta `PAY_6`). |

**Estado final**

Con 30,000 registros consolidados y sin identificadores ruidosos, la base de datos queda lista para la exploración mediante consultas agrupadas.

# Exploración mediante SQL

# Panorama general y Balance de Clases

Las primeras consultas (`COUNT` y `GROUP BY`) sobre los 30,000 registros revelan la distribución fundamental del riesgo en la cartera.

**Cuadro 2:** Balance de la Variable Objetivo (`default_payment`)

| Estado | Cantidad de Clientes | Proporción |
|---|---|---|
| 0 (Solvente / No Default) | 23,364 | 77.88 % |
| 1 (Incumplimiento / Default) | 6,636 | **22.12 %** |
| **Total Cartera** | 30,000 | 100.00 % |

## El desafío del desbalance

La base de datos muestra un desbalance natural y esperado en finanzas: aproximadante 1 de cada 5 clientes entra en mora. Este **22.12 %** anticipa que el modelo requerirá métricas de evaluación específicas para no ser engañado por la clase mayoritaria.

# Asignación de Crédito por Nivel Educativo

Cruzando el límite de crédito (`LIMIT_BAL`) con el nivel educativo (`EDUCATION`), observamos las políticas estructurales de la entidad.

| Código | Nivel Educativo | Límite Promedio Asignado (TWD) |
|---|---|---|
| 1 | Posgrado / Escuela de Graduados | $212,956.07 |
| 4 | Otros / Desconocido | $181,316.24 |
| 2 | Universidad | $147,062.44 |
| 3 | Bachillerato / Secundaria | $126,550.27 |

## La lógica de la asignación

Existe una correlación directa en las políticas del banco: a mayor grado de escolaridad formal comprobable, se asignan cupos significativamente más altos. El segmento "Otros" presenta un promedio elevado, sugiriendo posibles perfiles ejecutivos o comerciales atípicos.

# Comportamiento Demográfico: Género y Estado Civil

Agrupando por variables categóricas, perfilamos cómo se distribuye el incumplimiento en distintos segmentos sociales.

### Estado Civil y Default

- **Casados (1):** 23.4 % de incumplimiento (3,206 de 13,659).
- **Solteros (2):** 20.9 % de incumplimiento (3,341 de 15,964).

Los clientes casados muestran una propensión al impago ligeramente mayor.

### Retrasos por Género

Al filtrar clientes con retrasos iniciales (`PAY_1` > 0):

- El género 2 (Mujeres) presenta mayores volúmenes absolutos de retrasos leves (ej. 2,196 vs 1,492 en retraso de 1 mes).
- Sin embargo, es necesario contrastar esto con la proporción total de mujeres en la muestra.

# Salud Financiera: Deuda, Pagos y Riesgo Crítico

Por último, analizamos la relación de liquidez real de los clientes en el mes más reciente (`AMT1`).

### Promedios Globales

- **Factura (`BILL_AMT1`):** $51,223.33
- **Abono (`PAY_AMT1`):** $5,663.58

El cliente promedio abona apenas cerca del 11 % de su deuda facturada.

### Riesgo Crítico (`PAY_1` $\geq$ 2)

La consulta para identificar clientes que actualmente presentan un retraso severo (2 meses o más) arrojó un total de **3,130** clientes.

### Interpretación para el Modelo

Tener más de 3,000 clientes en riesgo críticoza consolidado al mes de corte indica que el historial de pagos será el vector principal para definir la frontera matemática entre solventes y deudores.

# Análisis Exploratorio (EDA)

# Resumen Estadístico (Variables Clave)

Un primer escaneo numérico revela la escala, centralidad y dispersión de las dimensiones predictoras más relevantes:

| Variable | Mínimo | Mediana (50 %) | Media | Máximo |
|---|---|---|---|---|
| LIMIT_BAL | $10k | $140k | **$167k** | $1M |
| AGE | 21 | 34 | **35.5** | 79 |
| BILL_AMT1 | -$165k | $22k | **$51k** | $964k |
| PAY_AMT1 | $0 | $2.1k | **$5.6k** | $873k |

*Nota: Los valores financieros están redondeados en TWD. k = miles, M = millones.*

# Diagnóstico Inicial de los Datos

De la tabla anterior extraemos conclusiones fundamentales que definen la naturaleza del riesgo en la muestra:

- **Asimetría Positiva (Sesgo):** En variables financieras, la media siempre es superior a la mediana. Una minoría de clientes con límites o deudas masivas desplazan el promedio hacia la derecha.
- **Leptocurtosis Extrema:** En `PAY_AMT1`, la mediana ($2.1k) es una fracción ínfima del máximo ($873k), indicando que la gran mayoría de la población realiza abonos mínimos en la base de la distribución.
- **Anomalías Aisladas:** Registros de facturación negativa (hasta -$165k) representan acreencias a favor del cliente (devoluciones o sobrepagos) y no constituyen errores de digitación.

# Distribuciones

Analizamos visualmente la concentración de los datos para las cuatro variables continuas principales.

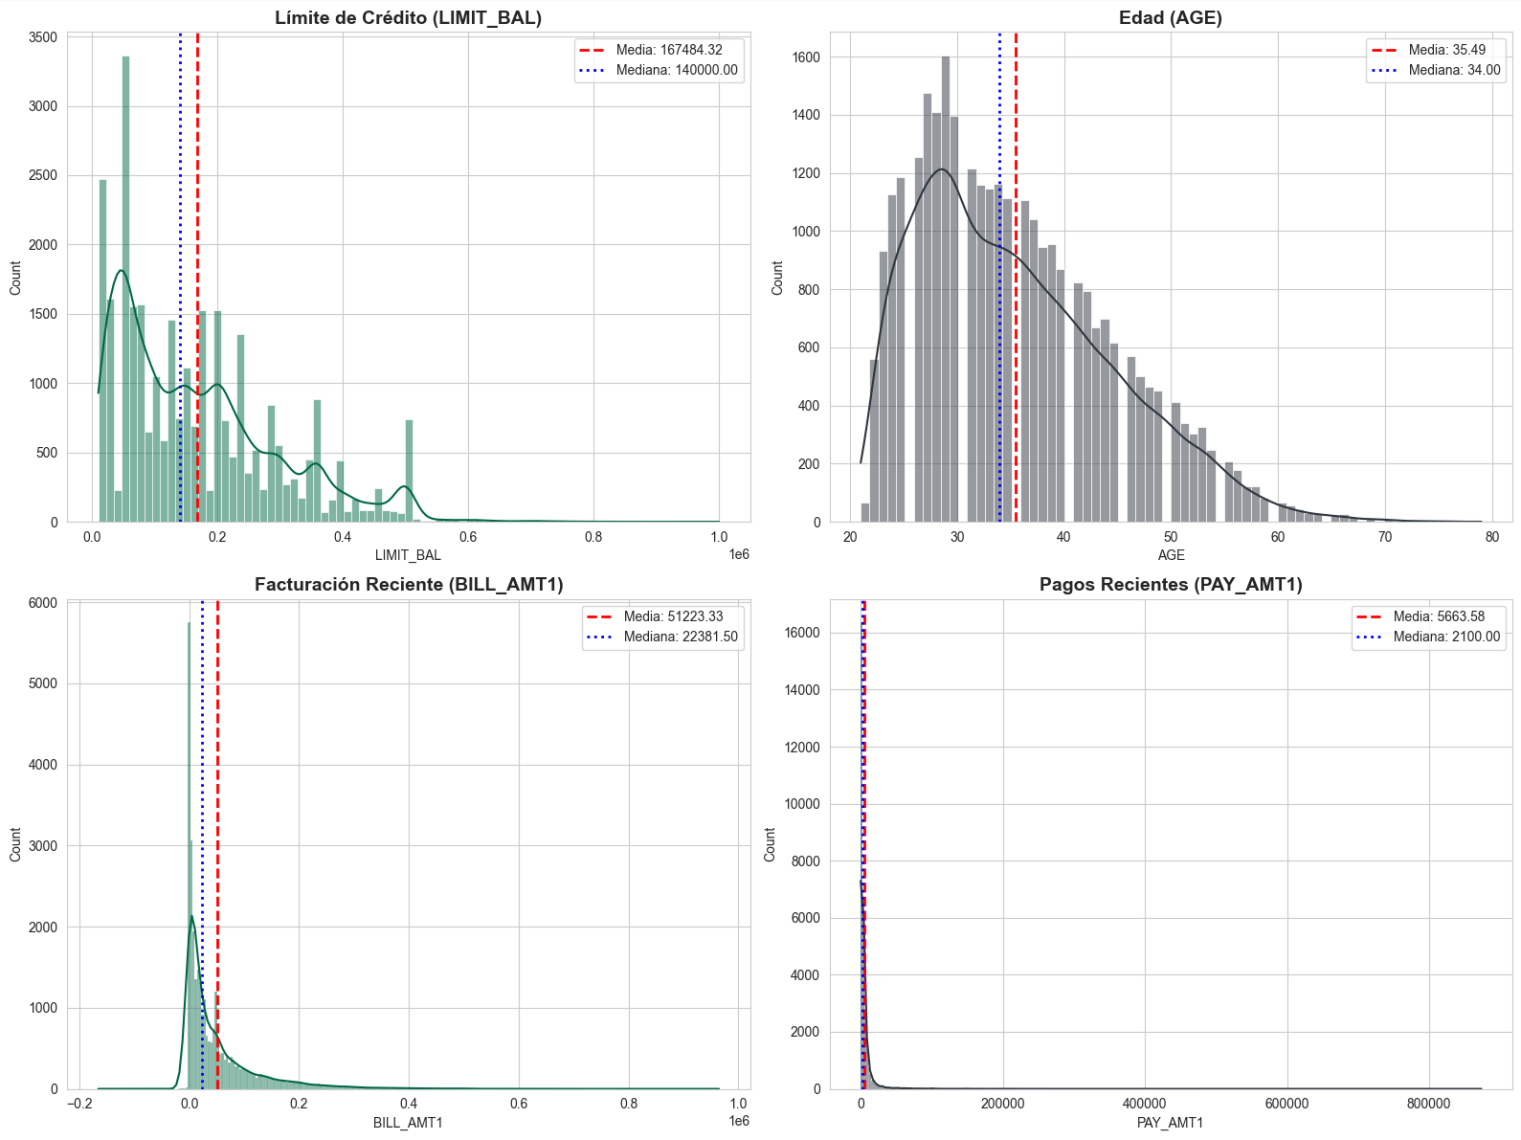

# Interpretación

### 1. El Sesgo Bancario (`LIMIT_BAL`)

La distribución es asimétrica con picos en valores redondos (50k, 100k, 200k). Esto no es azar; refleja políticas predeterminadas de asignación de cupos de la entidad.

### 2. Estabilidad Demográfica (`AGE`)

Presenta la morfología más cercana a la normalidad. La densidad se concentra entre los 25 y 40 años, representando el segmento central de actividad económica y consumo.

### 3. El "Aplastamiento" Financiero

Tanto la facturación como los pagos exhiben una escala tan extendida por valores atípicos que el 95 % de la población queda comprimida visualmente al inicio de la gráfica.

### 4. Riesgo de Apalancamiento

La aguda distancia entre la deuda masiva y los pagos mínimos sugiere un alto nivel de endeudamiento relativo en la cartera.

# Identificación de Valores Atípicos (Outliers)

# Diagramas de Caja: Detección de Valores Extremos

Evaluamos la dispersión y la presencia de observaciones inusuales utilizando la regla del Rango Intercuartílico (IQR).

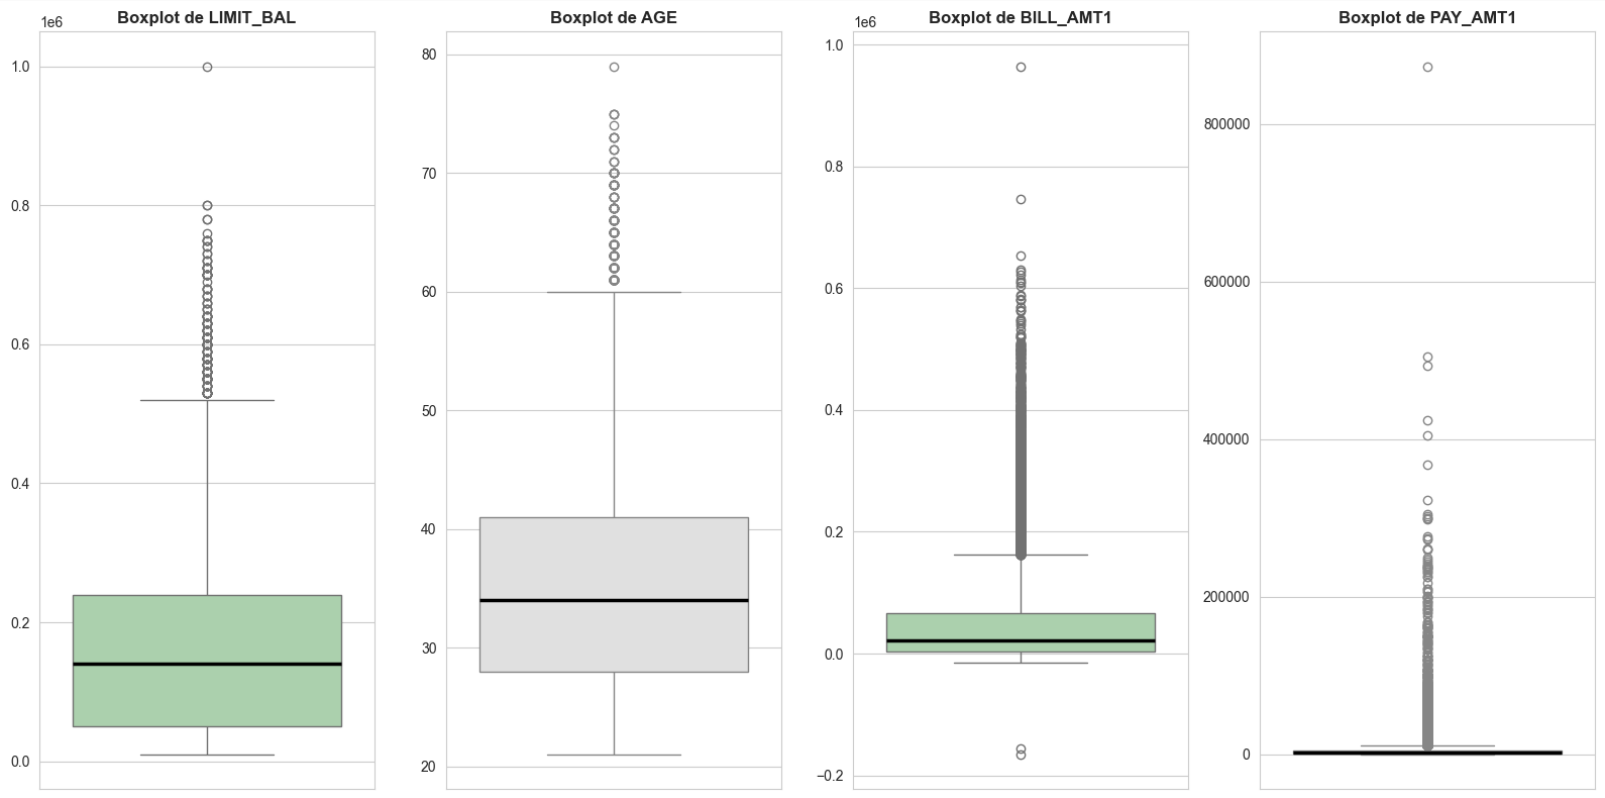


**Figura 2:** Identificación de outliers multidimensionales en variables financieras y demográficas.

# Cuantificación de Valores Atípicos ($1{,}5 \times IQR$)

El cálculo exacto de registros atípicos revela una clara distinción entre el perfil del cliente y su comportamiento transaccional:

| Variable | Cant. Outliers | % del Total |
|---|---|---|
| LIMIT_BAL | 167 | **0.56 %** |
| AGE | 272 | **0.91 %** |
| BILL_AMT1 | 2,400 | **8.00 %** |
| PAY_AMT1 | 2,745 | **9.15 %** |

**Dualidad de Volatilidad**

Mientras las variables de perfil (LIMIT_BAL, AGE) son sumamente controladas ($< 1\,\%$ de anomalías), las dimensiones transaccionales exhiben una extrema volatilidad (hasta un 9,15 % de atípicos).

¿Debemos eliminar o truncar estos valores extremos para mejorar la distribución matemática?

### Justificación de Permanencia (Criterio de Riesgo)

En el contexto de la Analítica de Riesgo Financiero, la presencia de *outliers* no debe interpretarse como error de captura, sino como **eventos de alto impacto**:

1. **Representatividad:** Los clientes con deudas o pagos masivos son precisamente los que representan el mayor riesgo sistémico para el banco.
2. **Frontera de Clasificación:** Eliminar el 9 % de los registros borraría la información de los casos más críticos que el modelo debe aprender a identificar.

### Decisión

Se opta por **conservar la totalidad de los atípicos**. Su tratamiento se delegará a la robustez intrínseca de los algoritmos elegidos (como Árboles de Decisión o Ensambles).

# Análisis de Correlación Lineal (Pearson)

# Matriz de Correlación de Pearson

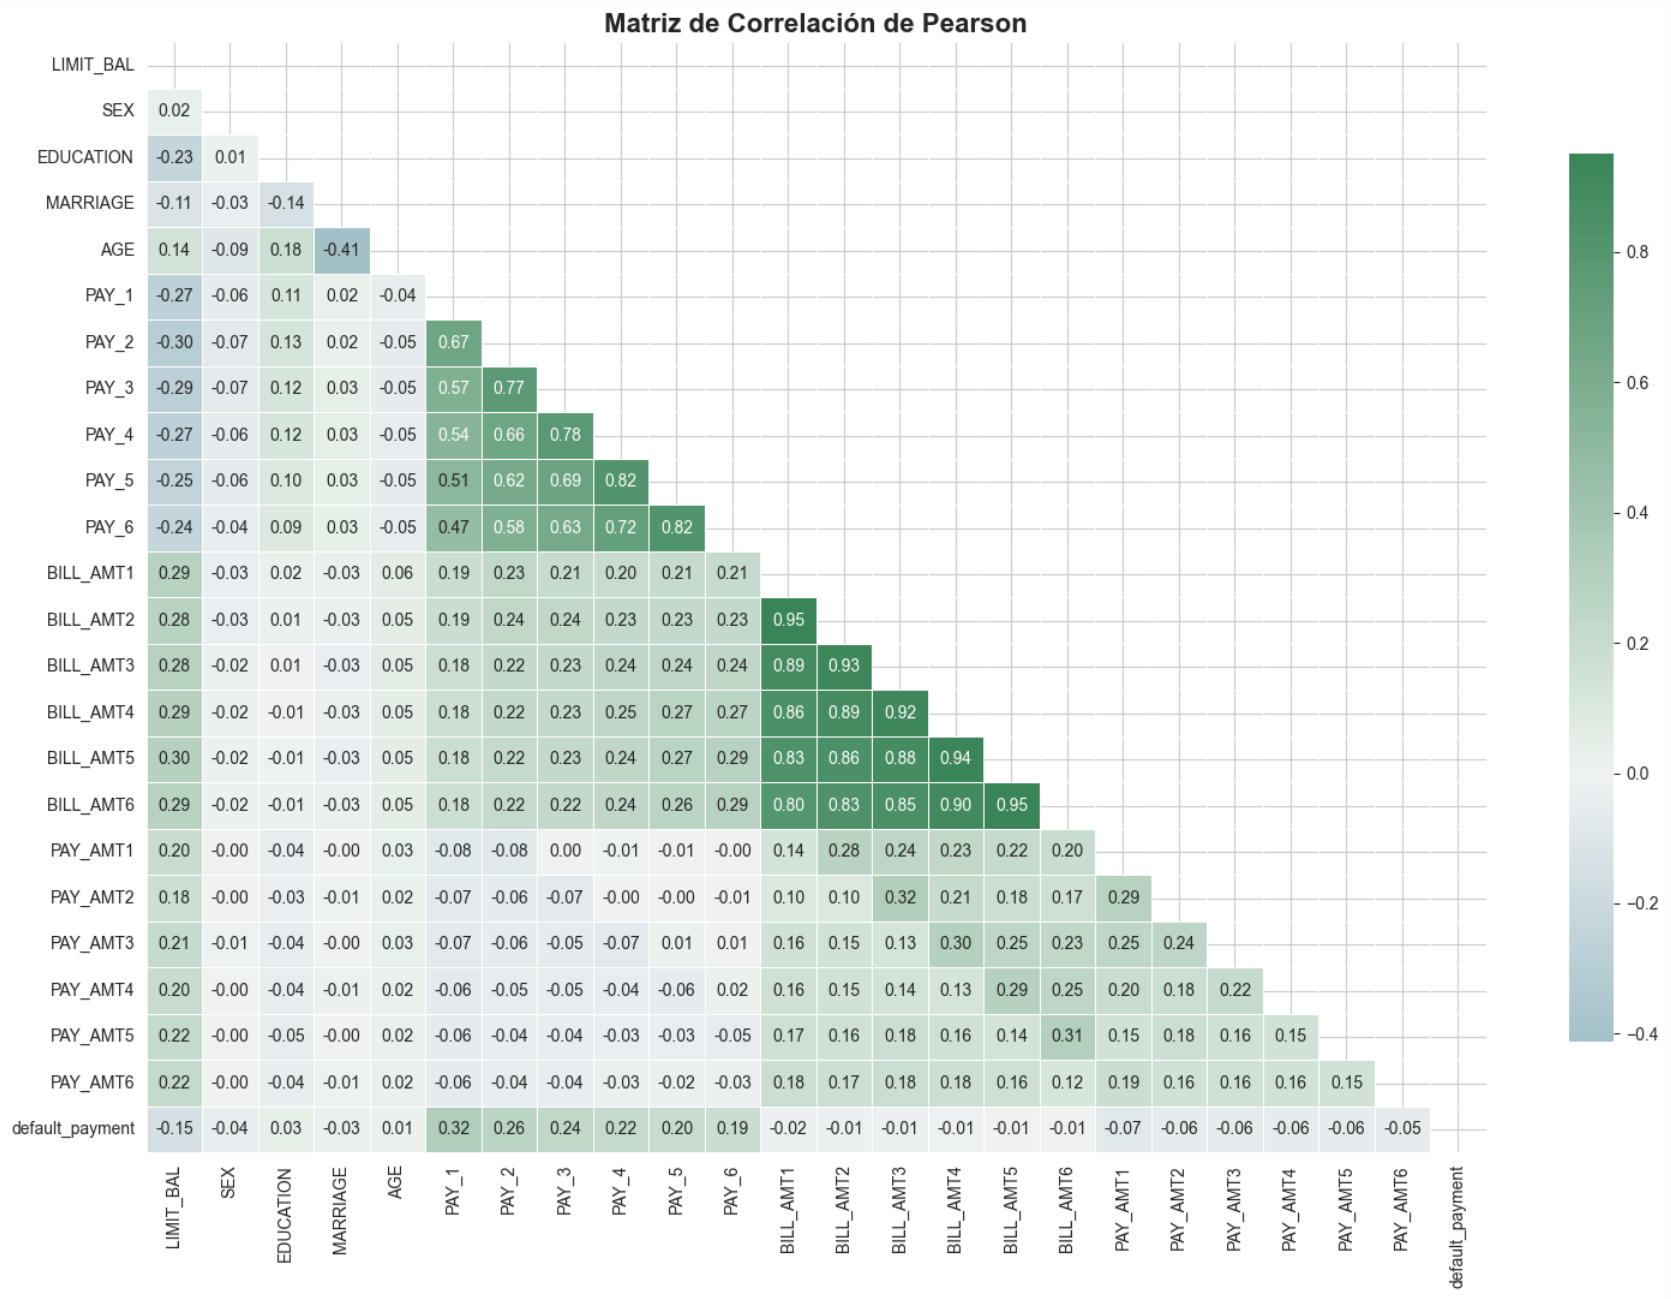

# Dinámicas Internas: Facturación e Historial

El mapa de calor revela patrones de interdependencia entre las variables predictoras, destacando dos bloques fundamentales:

## 1. Multicolinealidad Crítica (`BILL_AMT1` a `BILL_AMT6`)

Se observa un bloque de alta correlación ($r > 0{,}90$) entre los estados de cuenta. El monto de la deuda actual está casi totalmente determinado por la deuda anterior.
**Implicación para el Modelo:** Incluir las 6 variables generará redundancia computacional; el algoritmo se beneficiará de una simplificación dimensional,

## 2. El "Efecto de Arrastre" (`PAY_1` a `PAY_6`)

Existe una correlación moderada-alta (rango $0{,}45 - 0{,}68$) entre los estados de mora consecutivos. Esto evidencia que un cliente que entra en mora reciente (`PAY_1`) muy probablemente ya arrastraba problemas de liquidez estructurales desde meses pasados.

# Determinantes del Incumplimiento (`default_payment`)

Al cruzar los predictores con nuestra variable objetivo (última fila de la matriz), contrastamos estadísticamente nuestras hipótesis:

### 3. Relación con el Riesgo

- `PAY_1`**:** Mayor correlación global ($\approx$ 0,32). Valida la **H1**: el comportamiento más reciente es el mejor predictor.
- `LIMIT_BAL`**:** Presenta correlación negativa. Valida la **H2**: a mayor cupo asignado, existe una menor probabilidad matemática de default.

### 4. Independencia Demográfica

Las variables `AGE`, `SEX` y `MARRIAGE` muestran correlaciones lineales casi nulas, tanto frente a la variable objetivo como frente a la estructura de la deuda.

### Conclusión del Análisis Lineal

El riesgo de impago en este dataset es un fenómeno impulsado primordialmente por la **conducta transaccional** y la gestión de la deuda, relegando las características biográficas a un segundo plano.

# Relaciones Bivariadas: Análisis del Riesgo

# Panel de Relaciones: Predictores vs. Default

Evaluamos el poder discriminatorio de las variables continuas agrupándolas por la clase objetivo (`default_payment`). Buscamos desplazamientos significativos en las medianas y en los rangos intercuartílicos (*IQR*).

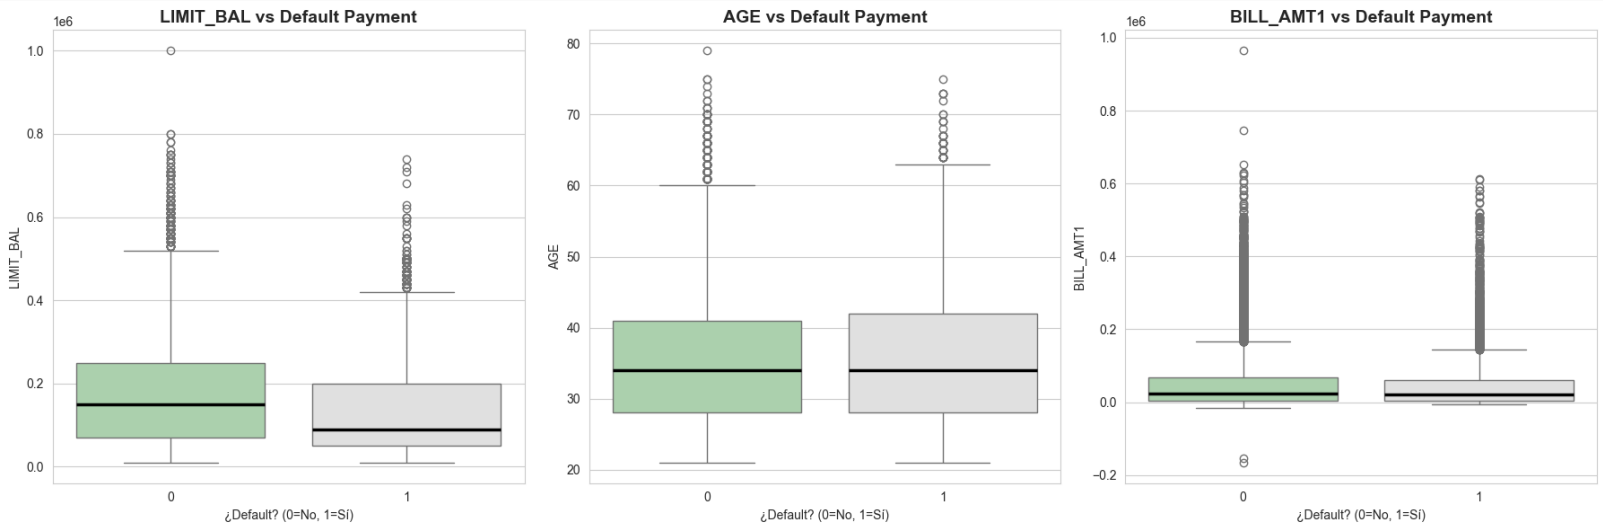


**Figura 3:** Boxplots comparativos: Pagadores (0) vs. Incumplimiento (1).

# Poder Discriminatorio: Límite y Edad

### 1. Límite de Crédito (`LIMIT_BAL`)

**Observación:** La mediana del grupo en default (1) es notablemente inferior al grupo solvente.
**Interpretación:** Existe una relación inversa robusta entre el cupo otorgado y el riesgo. El sistema de *scoring* previo ya detectaba mayor riesgo en estos perfiles, asignándoles menor capacidad de apalancamiento.
**Poder Predictivo:** Alto. Fundamental para separar las clases.

### 2. Demografía (`AGE`)

**Observación:** Las medianas de ambos grupos se sitúan casi en el mismo nivel ($\approx$ 34 años), con un solapamiento total entre los cuartiles $Q_1$ y $Q_3$.
**Interpretación:** La distribución de la edad es homogénea. La edad no discrimina el riesgo de impago, actuando solo como una variable de control demográfico.
**Poder Predictivo:** Bajo.

# Dinámica de Deuda y Conclusión Bivariada

### 3. Facturación Reciente (`BILL_AMT1`)

A pesar de la extrema volatilidad en la cola superior, las cajas principales de ambos grupos se mantienen en niveles de deuda asombrosamente similares. El monto bruto adeudado no es un indicador definitivo; el riesgo reside en la proporción de esa deuda frente a la capacidad de abono mensual.

**Poder Predictivo:** Moderado-Bajo.

## Síntesis Estratégica para el Modelo

El análisis de varianza visual confirma categóricamente que el **comportamiento crediticio** (historial de cupos y liquidez) posee un peso estadístico muy superior a las **características biográficas** (edad) para trazar la frontera matemática de decisión. Se priorizarán las variables financieras en la fase de entrenamiento.

# Tratamiento de Datos Faltantes (Simulación)

# Simulación de Datos Faltantes (Stress Test)

Dado que el dataset original presenta una integridad total (0 nulos), se diseñó un experimento de corrupción controlada para evaluar la robustez algorítmica ante futuras inconsistencias.

## Metodología de Pérdida Aleatoria (MCAR)

Se indujo una pérdida aleatoria del **1 %, 5 % y 10 %** en la variable `LIMIT_BAL` (Límite de Crédito), utilizando una semilla para asegurar la reproducibilidad.

- **Métodos Evaluados:** Mediana (Univariado), KNN (Multivariado por similitud) e Iterative Imputer (MICE, multivariado paramétrico).
- **Métrica de Control:** Se utilizó el *Root Mean Squared Error* (RMSE) para penalizar desviaciones severas en las colas de la distribución:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_{original} - y_{imputado})^2}$$

# Resultados de la Simulación (RMSE)

Evaluamos el desempeño de cada método según su capacidad para minimizar el error de reconstrucción en los tres escenarios de estrés:

| Escenario | RMSE Mediana | RMSE KNN | RMSE Iterative | Ganador |
|---|---|---|---|---|
| 1 % Pérdida | 123,982.52 | **112,921.50** | 115,658.25 | **KNN** |
| 5 % Pérdida | 130,799.59 | **116,544.28** | 121,672.65 | **KNN** |
| 10 % Pérdida | 130,554.07 | **117,860.98** | 122,029.69 | **KNN** |

**Superioridad del KNN (K-Nearest Neighbors)**

En todos los niveles de pérdida, el KNN obtuvo el RMSE más bajo. El límite de crédito no es aleatorio; está correlacionado con el perfil socioeconómico. KNN captura estas relaciones no lineales al consultar los valores de los vecinos más cercanos en el espacio $n$-dimensional.

# Decisión

### Debilidad de la Mediana

En una distribución con sesgo positivo, imputar un valor constante ($140,000) destruye la varianza original. El RMSE penaliza severamente los errores masivos cometidos al intentar imputar datos que pertenecían a un "outlier" de alto cupo.

### Desempeño Iterativo (MICE)

Aunque utiliza regresiones encadenadas, el enfoque paramétrico se mantuvo por debajo del KNN. La técnica basada en similitud directa ("vecindad") demostró ser más robusta para este tipo de datos.

### Conclusión del Experimento

Se establece como regla el método **KNN** para tratar futuros valores nulos. La reducción del error (mejora aproximada del 10-12 % sobre la Mediana) justifica plenamente el costo computacional adicional, garantizando que el modelo reciba datos de alta fidelidad.

# Pruebas de Asociación y Dependencia

# Estrategia Estadística: Validación de EDA

Para confirmar si las relaciones observadas visualmente tienen significancia real frente al incumplimiento (`default_payment`), definimos la siguiente batería de pruebas bajo $\alpha = 0{,}05$:

- **Prueba $\chi^2$ de Independencia (Categóricas):** Evalúa variables como `SEX`, `EDUCATION` y `MARRIAGE`.

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

- **Correlación de Spearman (Numéricas):** Dado el sesgo y los valores atípicos, se prefiere Spearman sobre Pearson al evaluar la relación monótona por rangos.
- **Kruskal-Wallis (Mixtas):** Alternativa no paramétrica al ANOVA. Compara si las medianas de una variable continua (ej. `LIMIT_BAL`) difieren significativamente entre los grupos de `default` (0 vs. 1).

# Resultados de Significancia Estadística

**Cuadro 3:** Pruebas $\chi^2$ (Categóricas)

| Variable | Stat $\chi^2$ | p-value |
|---|---|---|
| EDUCATION | 160.41 | $1{,}4 \times 10^{-34}$ |
| SEX | 47.70 | $4{,}9 \times 10^{-12}$ |
| MARRIAGE | 28.13 | $7{,}7 \times 10^{-7}$ |

**Cuadro 4:** Kruskal-Wallis y Spearman (Numéricas)

| Variable | Stat $H$ | Coef $\rho$ | p-value |
|---|---|---|---|
| LIMIT_BAL | 862.75 | -0.169 | $< 10^{-189}$ |
| PAY_AMT1 | 772.71 | -0.160 | $< 10^{-169}$ |
| BILL_AMT1 | 19.24 | -0.025 | $1{,}1 \times 10^{-5}$ |
| AGE | 0.79 | 0.005 | **0.3725** |

**El Colapso de la Edad**

El estadístico de la edad arroja un $p$-value $> 0{,}05$. Matemáticamente no podemos rechazar la hipótesis nula; las distribuciones de edad entre pagadores y morosos son estadísticamente idénticas.

# Interpretación y Selección de Características

### 1. El "Poder" del Límite y los Pagos

`LIMIT_BAL` y `PAY_AMT1` muestran estadísticos grandes ($H \approx 862$ y 772). La correlación monótona negativa ($\rho \approx -0{,}17$) confirma que a mayor liquidez y cupo, la probabilidad de caer en default disminuye. Son predictores primarios.

### 2. La Verdad sobre la Facturación

Aunque `BILL_AMT1` tiene significancia ($p < 0{,}05$), su estadístico $H$ (19.2) y su coeficiente $\rho$ (-0.02) palidecen frente al historial de pagos. El monto de la deuda bruta es casi ruido.[en] comparación con la capacidad de abono.

### 3. Aporte Categórico

Todas las variables categóricas rechazaron fuertemente la hipótesis nula de independencia ($p \approx 0$). Aportan información estructural sólida, complementando la señal de las variables numéricas.

# Validación Integral de las Hipótesis

# Sentencia de Hipótesis (I)

Con base en la evidencia paramétrica y no paramétrica, dictaminamos el cumplimiento de los supuestos iniciales:

### Hipótesis 1: Prevalencia del Comportamiento Reciente (CONFIRMADA)

**Evidencia:** La variable `PAY_1` exhibió la correlación de mayor magnitud con el default ($r \approx 0{,}32$). Adicionalmente, el análisis de Spearman para `PAY_AMT1` arrojó un $p < 10^{-170}$.
**Conclusión:** El comportamiento financiero inmediato posee el mayor peso predictivo. Los retrasos en el periodo actual constituyen indicadores de riesgo significativamente más robustos que el historial transaccional remoto.

### Hipótesis 2: El Límite de Crédito como Indicador de Solvencia (CONFIRMADA)

**Evidencia:** El estadístico $H$ de Kruskal-Wallis resultó ser el más elevado entre las variables continuas (862,75). Los diagramas de caja confirmaron el desplazamiento de las medianas.
**Conclusión:** Se ratifica una relación inversa entre el cupo asignado y la probabilidad de default. El límite de crédito actúa como un filtro de riesgo derivado de los procesos de evaluación previa de la entidad.

# Sentencia de Hipótesis (II) y Directrices Estratégicas

### Hipótesis 3: La Edad como Factor de Riesgo Directo (RECHAZADA)

**Evidencia:** La prueba de Kruskal-Wallis arrojó un $p$-value $= 0{,}3725$ ($> 0{,}05$).
**Conclusión:** No existe evidencia estadística para afirmar que la edad influye en el incumplimiento. El riesgo crediticio en esta muestra es de naturaleza estrictamente conductual y financiera, no demográfica.

### Hipótesis 4: El Nivel Educativo como Factor de Mitigación (CONFIRMADA)

**Evidencia:** Se registró la mayor fuerza de asociación entre variables categóricas ($\chi^2 = 160{,}41$, $p \approx 0$).
**Conclusión:** El grado de instrucción formal no es independiente de la probabilidad de impago. Estadísticamente, niveles educativos superiores se asocian con una menor propensión al default.

**¿Preguntas?**