Análisis Exploratorio y Determinantes de Valoración

Caso de Regresión: Mercado Inmobiliario de King County

Juan Camilo Ramirez Diaz

15 de abril de 2026

Matemáticas — Universidad de Antioquia

Contexto y Definición

Contexto del Conjunto de Datos

El proyecto se fundamenta en el análisis de transacciones inmobiliarias reales en el estado de Washington.

- **Nombre:** *House Sales in King County, USA*.
- **Fuente:** Repositorio público de Kaggle (original de Harlfoxem).
- **Periodo de captura:** Datos recolectados entre **mayo de 2014** y **mayo de 2015**.
- **Alcance Geográfico:** Condado de King, incluyendo la ciudad de Seattle y sus alrededores.
- **Volumen:** 21,613 observaciones con 21 variables predictoras.

Ubicación Geográfica: Condado de King

Para entender la dinámica de precios, es fundamental ubicar el mercado en el noroeste de los Estados Unidos.

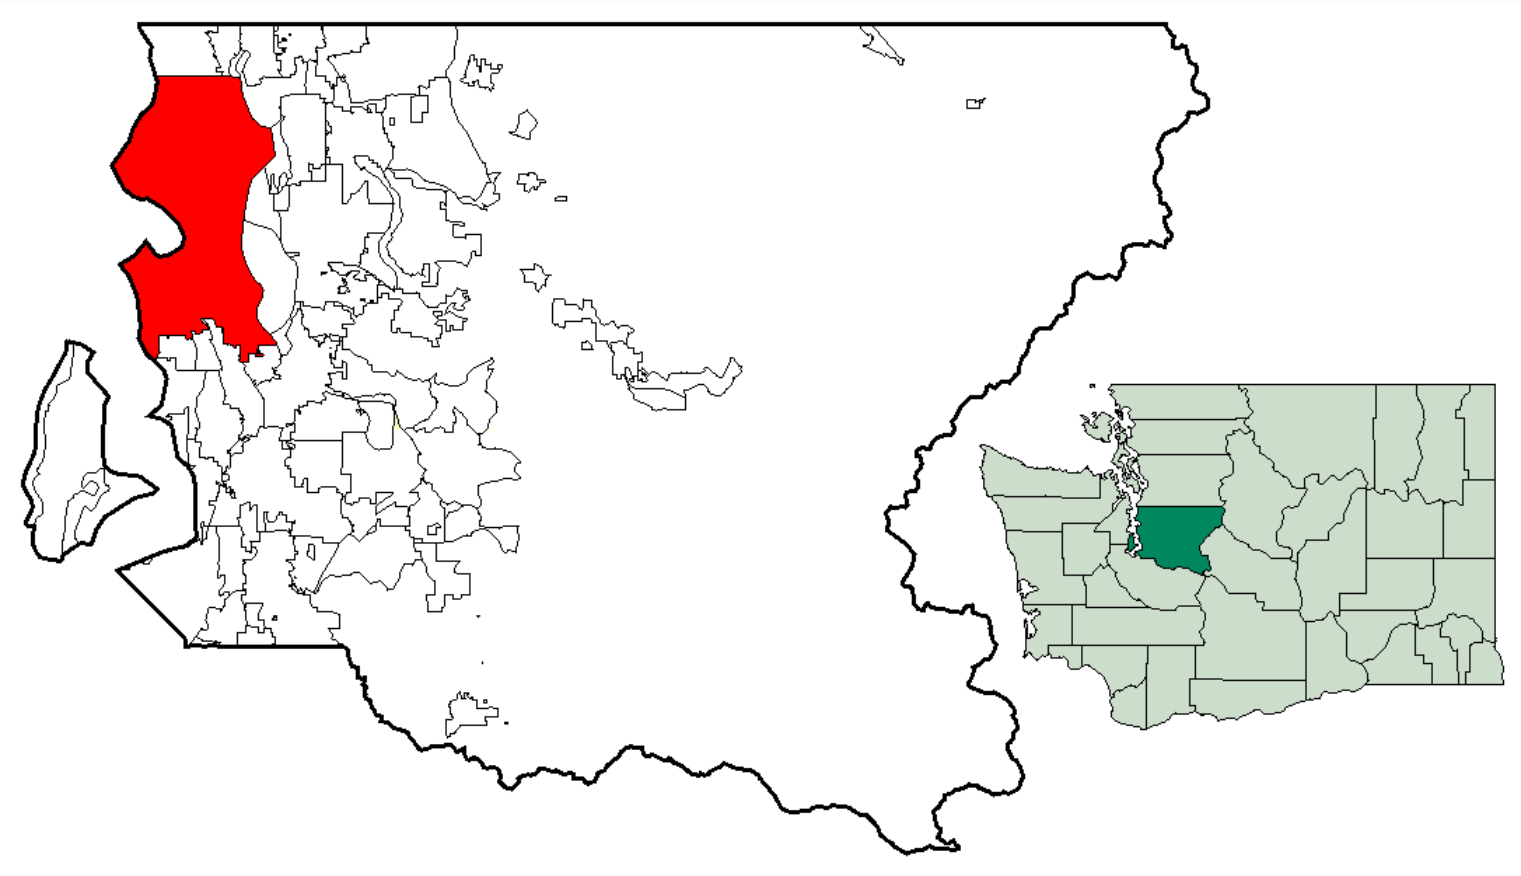

Figura 1: Área de estudio: King County, WA.

Dimensiones Críticas del Análisis

Se detallan las 8 variables de mayor peso estadístico y aporte informativo identificadas en el EDA:

Variable	Descripción	Naturaleza
price	Valor de venta de la vivienda en USD.	Continua (Target)
`sqft_living`	Superficie habitable interior de la propiedad.	Num. Continua
`grade`	Índice de calidad de construcción y diseño estructural.	Num. Ordinal
`lat`	Ubicación geográfica en el eje Norte-Sur (Latitud).	Num. Continua
`long`	Ubicación geográfica en el eje Este-Oeste (Longitud).	Num. Continua
`bathrooms`	Número de baños (incluye fracciones por medios baños).	Num. Continua
`view`	Valoración estética de la vista desde la propiedad.	Num. Ordinal
`waterfront`	Presencia de frente o acceso directo al agua.	Cat. Binaria

Variables adicionales analizadas: *bedrooms, sqft_lot, floors, condition, sqft_above, sqft_basement, yr_built, yr_renovated, zipcode, sqft_living15, sqft_lot15.*

¿Por qué priorizamos el lugar?

Lo que no se puede cambiar

Puedes remodelar toda la casa, pero nunca podrás moverla de donde está. El lugar es el único factor que realmente permanece y se esperaría que aporte en buena medida al valor base de la propiedad.

- **Comprar el barrio:** La ubicación resume factores como seguridad o cercanía al trabajo que no siempre están escritos en una tabla.
- **Detalles únicos:** Una buena vista o estar frente al agua no se pueden fabricar; son los detalles que hacen especial a una propiedad.
- **Nuestra base:** Antes de ver los cuartos, queremos entender el sector. Es el primer paso para analizar el panorama completo.

Gestión de Datos y Extracción

De los datos crudos a la base de datos

Antes de consolidar la información, llevamos los datos a un proceso intermedio para organizar las etiquetas y los formatos, asegurando que todo esté listo para trabajar sin ruidos.

- **El camino:** Pasamos de un archivo plano (`CSV`) a un motor de base de datos (`SQLite`).
- **Organización:** En este paso ajustamos los tipos de datos (fechas, números y categorías) para que las consultas sean rápidas y precisas.
- **Resultado:** Una tabla estructurada y limpia que nos permite centrarnos en el análisis y no en corregir errores de formato.

Ajustes y nuevas dimensiones

Cuadro 1: Variables transformadas

Variable	Acción	Justificación
`id`	Removida	Es un código de registro que no influye en el valor.
`date`	Ajustada	Se separó en año y mes para ver tendencias en el tiempo.
`zipcode`	Etiquetada	Se trata como texto para evitar cálculos matemáticos con códigos postales.

Cuadro 2: Variables creadas

Nueva Variable	Origen	Aporte al análisis
is_renovated	`yr_renovated`	Indica simplemente si la casa fue remodelada o no.
sale_year / month	`date`	Permiten ver cómo cambia el mercado según la época.

Estado final

Esta preparación estandarizó la información, dejándola lista para iniciar el análisis exploratorio.

Exploración mediante SQL

Panorama general y dimensiones

Cuadro 3: Rangos de Precio y Área Habitable

Métrica	**Precio (USD)**	**Área (ft^2)**
Mínimo	$75,000.00	290
Máximo	$7,700,000.00	13,540
Promedio	$540,088.14	2,079.90

Habitaciones	1	2	3	4	5	6
Precio Prom.	$317k	$401k	$466k	$635k	$786k	$825k

Lo que observamos

Existe una escala lógica donde el precio sube con el tamaño, pero la enorme brecha entre el promedio y los máximos confirma la presencia de un segmento de lujo muy marcado.

¿Cómo influye la calidad de construcción?

Grado	Cantidad	Precio Promedio
13	13	$3,709,615.38
12	90	$2,191,222.00
11	399	$1,496,841.73
10	1134	$1,071,771.07
9	2615	$773,513.19
8	6068	$542,852.77

Grado	Cantidad	Precio Promedio
7	8981	$402,590.26
6	2038	$301,919.64
5	242	$248,523.97
4	29	$214,381.03
3	3	$205,666.67
1	1	$142,000.00

El punto de inflexión

El grado 7 concentra la mayor oferta del mercado. Sin embargo, a partir del grado 10 el precio crece más bruscamente.

El segmento de lujo: Vista al agua

Cuadro 4: Top 5 Propiedades con Vista al Agua

Precio (USD)	Habitaciones	Baños	Área (ft^2)
$5,110,800.00	5	5.25	8,010
$3,075,000.00	4	5.00	4,550
$3,070,000.00	3	2.50	3,930
$2,400,000.00	4	2.50	3,650
$2,125,000.00	3	2.50	5,403

La importancia del entorno

El entorno multiplica el valor de forma desproporcionada. Una casa con vista al agua puede costar 6 veces más que el promedio, sin necesidad de tener 6 veces su tamaño.

Referencia de medidas: m^2 vs ft^2

Establecemos la relación de conversión para aterrizar las dimensiones al contexto local:

$$1\,m^2 \approx 10{,}7639\,ft^2$$

Cuadro 5: Escala de comparación: Colombia vs. Seattle

Referencia Local	**Área en m^2**	**Área en ft^2**
Apto. Estudiantil / Apartestudio	$\approx 30\,m^2$	$\approx 330\,ft^2$
Vivienda de Interés Social (VIS)	$\approx 50\,m^2$	$\approx 550\,ft^2$
Apartamento Estándar (3 hab)	$\approx 80\,m^2$	$\approx 880\,ft^2$
Promedio en Seattle	$\approx \mathbf{193\,m^2}$	$\mathbf{2,079\,ft^2}$

El mínimo ($290\,ft^2$)

Equivale a unos $27\,m^2$. Una dimensión mínima, similar a un apartestudio pequeño en sector universitario.

El máximo ($13,540\,ft^2$)

Equivale a $1,258\,m^2$. Una propiedad de gran escala que supera el área de una piscina olímpica mediana.

¿Cómo se ve el promedio en Seattle?

Una casa de aproximadamente **2,000 sqft** ($\approx 186\, m^2$) en el mercado de King County representa el estándar familiar típico.

Figura 2: Representación ilustrativa para una propiedad estándar ($\approx 2,000\, ft^2$).

Análisis Exploratorio (EDA)

Hipótesis de estudio

1. Área Habitable

Se espera una relación positiva entre `sqft_living` y `price`, siendo uno de los principales determinantes del valor.

2. Ubicación Geográfica

Las variables de localización (`lat`, `long`, `zipcode`) tienen un impacto significativo según la zona.

3. Calidad Estructural

Propiedades con mayor calidad de construcción (`grade`) y mejor condición física presentan precios más altos.

4. Amenidades Premium

Características como `waterfront` o mejores valores en `view` incrementan significativamente el precio.

5. Antigüedad y Renovación

Viviendas antiguas tienden a menor precio, salvo que `yr_renovated` mitigue o revierta este efecto.

6. Influencia del Entorno

Las características del vecindario (`sqft_living15`, `sqft_lot15`) influyen por el efecto de comparación.

Estas premisas guiarán la validación estadística en las siguientes secciones.

Resumen Estadístico (Variables Clave)

Un primer escaneo numérico revela la escala y dispersión de los datos. Se han filtrado las variables más críticas y abreviado los valores para facilitar la lectura:

Variable	Mínimo	Mediana (50 %)	Media	Máximo
price	$75k	$450k	**$540k**	$7.7M
sqft_living	290	1,910	**2,080**	13.5k
bedrooms	0	3	**3.4**	33
waterfront	0	0	**0.007**	1
yr_renovated	0	0	**84.4**	2015

Nota: Los valores de precio están en USD. k = miles, M = millones.

Diagnóstico Inicial de los Datos

De la tabla anterior extraemos conclusiones fundamentales que justifican el tratamiento de *outliers* y el análisis de distribuciones:

- **Asimetría Positiva (Sesgo):** En el precio y el área, la media es notablemente superior a la mediana ($540k vs $450k). Esto indica que un grupo reducido de propiedades muy costosas empuja el promedio hacia arriba.
- **Valores Extremos:** Los máximos ($7.7M en precio y 13.5k en área) confirman una *cola larga* en el mercado. Además, anomalías como el registro de 33 habitaciones exigen una limpieza.
- **Concentración y Ceros:** Variables como `waterfront` (media de 0.007) indican que menos del 1 % tiene vista al agua. Asimismo, la mediana de 0 en `yr_renovated` confirma que la inmensa mayoría de casas no han sido remodeladas.

Análisis Exploratorio (EDA)

Distribuciones Continuas: Precio y Área

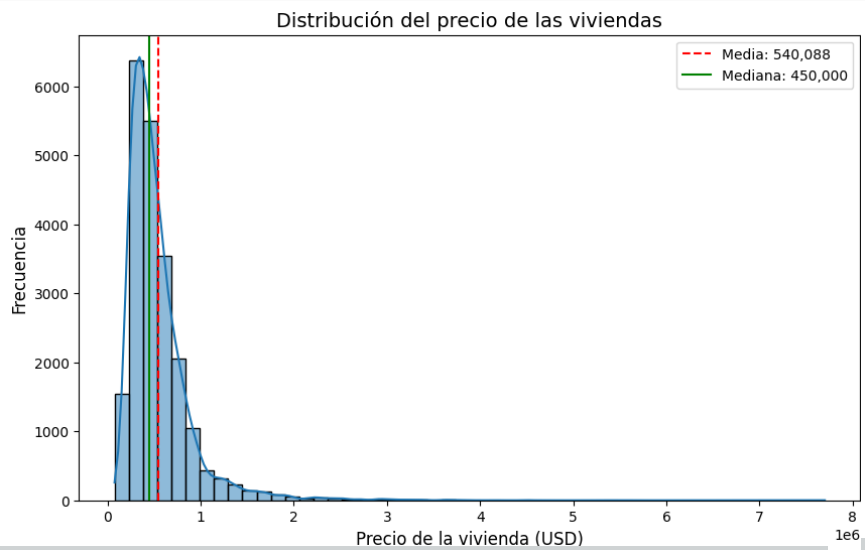

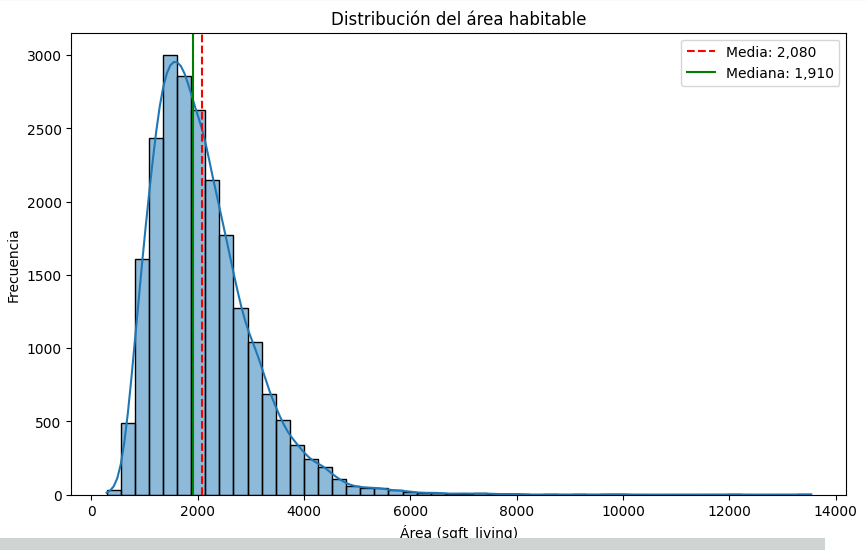

price

Asimetría positiva. La media ($540k) se encuentra desplazada a la derecha de la mediana ($450k). Esto confirma que el promedio está influenciado por las propiedades de alto valor que forman la "cola" de la distribución.

sqft_living

Sesgo a la derecha. Se observa un comportamiento análogo al precio. El promedio (2,080) es superior a la mediana (1,910), evidenciando que la distribución se estira hacia las viviendas de mayores dimensiones.

Atributos Estructurales: Calidad y Configuración

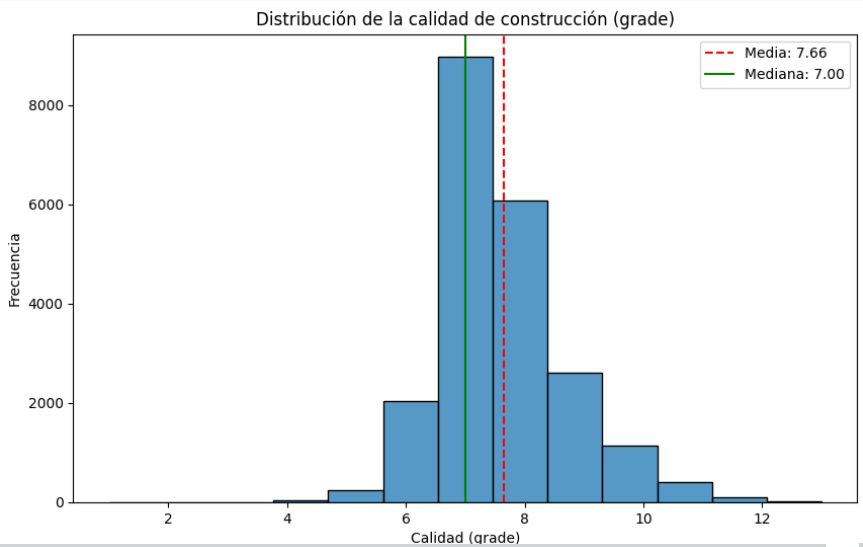

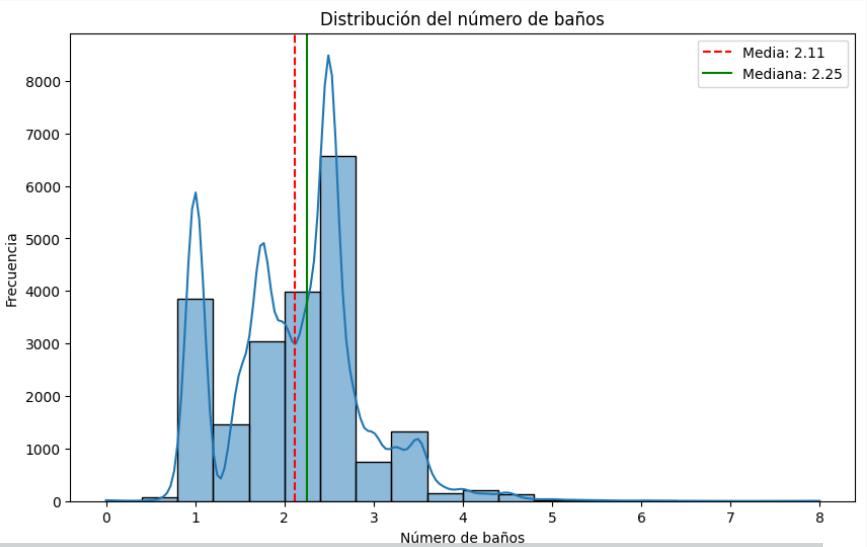

grade

Naturaleza ordinal. La densidad se concentra en los niveles 7 y 8. La frecuencia de las observaciones disminuye rápidamente al desplazarnos hacia los estándares de construcción de alta gama (11 a 13).

bathrooms

Comportamiento multimodal. Los picos reflejan configuraciones discretas (1.0, 2.0, 2.5). Esta fragmentación sugiere que la variable, por sí sola, no explica variaciones finas de precio como lo haría la ubicación.

Identificación de Valores Atípicos (Outliers)

Diagramas de Caja

Evaluamos la presencia de observaciones inusuales en las dimensiones de mayor impacto.

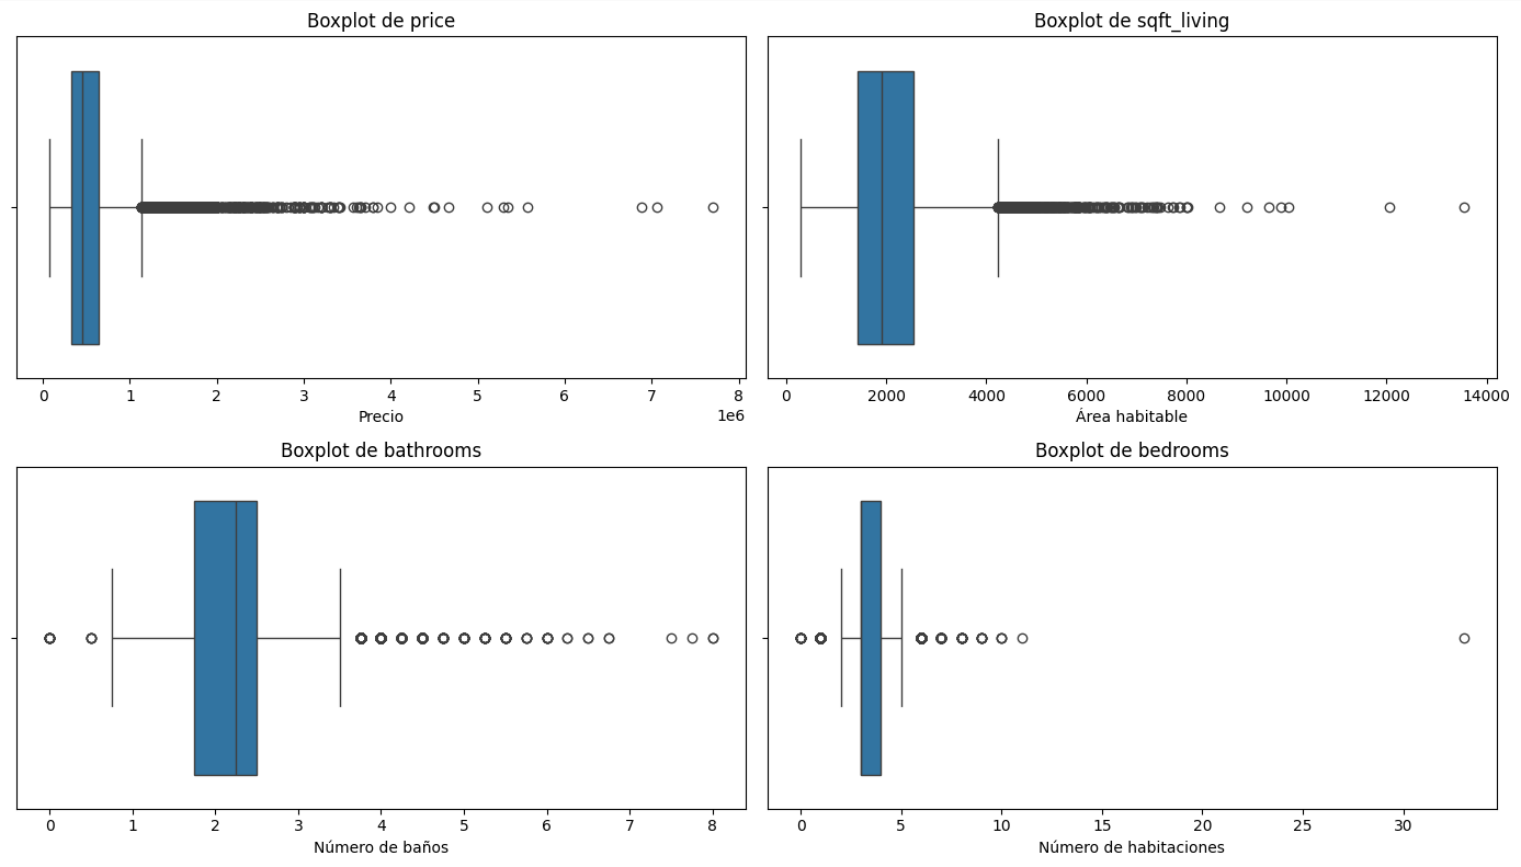

Figura 3: Distribución y detección de puntos extremos en variables críticas.

Cuantificación

Utilizando la regla de **1.5** $\times$ **IQR** para definir los límites de la distribución típica, se obtienen los siguientes resultados:

Variable	Límite Sup.	Límite Inf.	Cant. Outliers	% del Total
price	$1,129,575	-$162,625	1,146	**5.30 %**
`sqft_living`	4,234.5	-257.5	572	**2.64 %**
`bathrooms`	3.62	0.62	571	**2.64 %**
`bedrooms`	5.50	1.50	546	**2.52 %**

Postura de Análisis

La anomalía del **5.30 %** en el precio es **consistente con otras distribuciones** (área y calidad) y no responde a casos aislados o errores de recolección. Esta **coherencia multidimensional** justifica su permanencia en el dataset; eliminarlos generaría un **sesgo de truncamiento**, impidiendo que el modelo aprenda la dinámica real del segmento de lujo.

Filtro de Inconsistencias Multidimensionales

Para separar las propiedades de lujo genuinas de los verdaderos **errores de recolección**, contrastamos el comportamiento cruzado de las variables.

Regla de Inconsistencia: Identificamos observaciones donde una característica entra al **top 0.5 %** (extremo superior), pero sus variables dependientes permanecen estancadas (iguales o inferiores a la mediana).

Price	Bedrooms	Bathrooms	Sqft_living	Grade	Var. Extrema
$640,000	**33**	1.75	1,620	7	`bedrooms`
$520,500	6	2.50	1,880	7	`bedrooms`
$400,000	6	2.00	2,350	8	`bedrooms`
...	...	...	...	...	...

Diagnóstico

A diferencia del segmento de lujo que crece en todas sus dimensiones, el caso resaltado es físicamente implausible (33 habitaciones ocupando 1,620 ft^2 (aprox 4.5 m^2 por habitación) con menos de 2 baños). Se evidencia un error de digitación.

Análisis de Correlación Lineal

Matriz de Correlación de Pearson

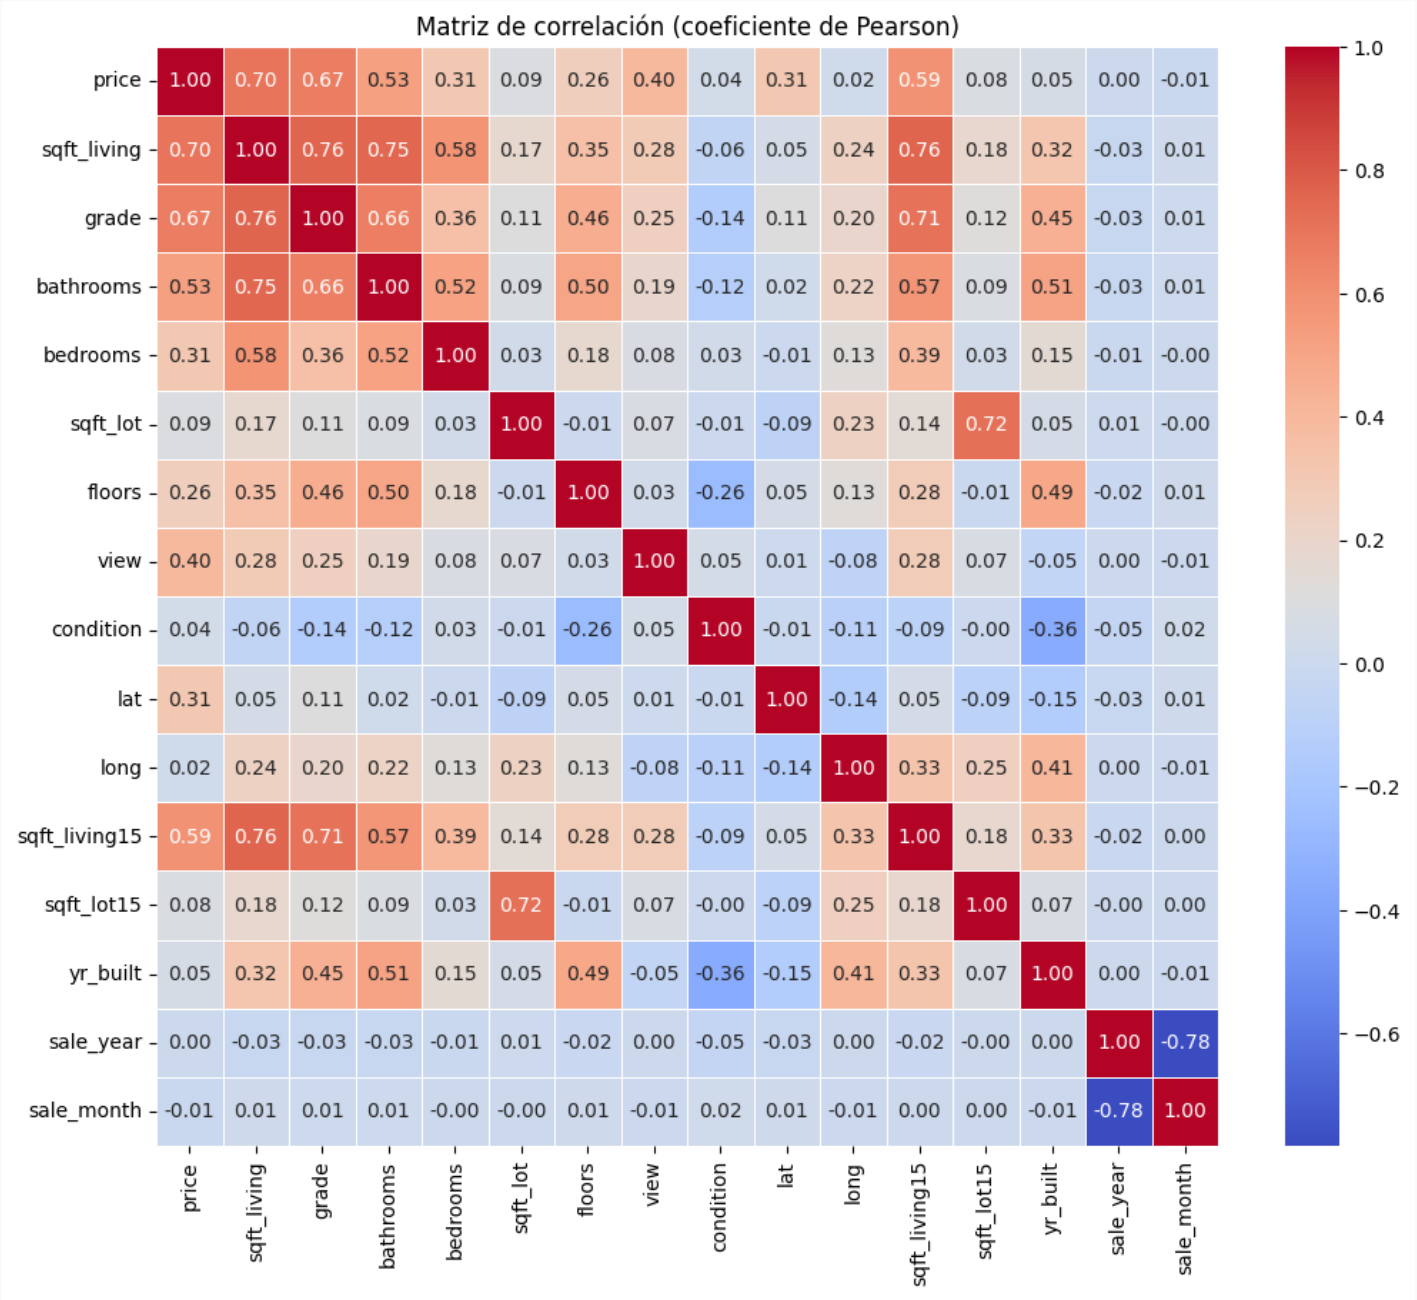

Determinantes Lineales del Precio

Fuerte Correlación (Motores Principales)

- `sqft_living` **(0.70):** Presenta la relación lineal más alta, confirmando al área habitable como el determinante primario del valor.
- `grade` **(0.67):** Valida la hipótesis de que la calidad de construcción tiene un impacto directo y contundente en el precio.

Correlación Moderada y Débil

- **Moderadas:** Entorno (`sqft_living15`: 0.59) y comodidad (`bathrooms`: 0.53) influyen positivamente, pero supeditados al área.
- **Débiles:** `bedrooms` (0.31) refuerza matemáticamente que aislar el número de cuartos sin considerar el área total no es un buen predictor.

La limitación de Pearson ante la Geografía

Variables como `lat` (0.31) y `long` (0.02) muestran valores bajos. Sin embargo, la ubicación ejerce efectos de concentración espacial que son **no lineales**; Pearson no captura esta complejidad.

Relaciones Bivariadas: Análisis del Precio

Panel de Relaciones: Atributos vs. Precio

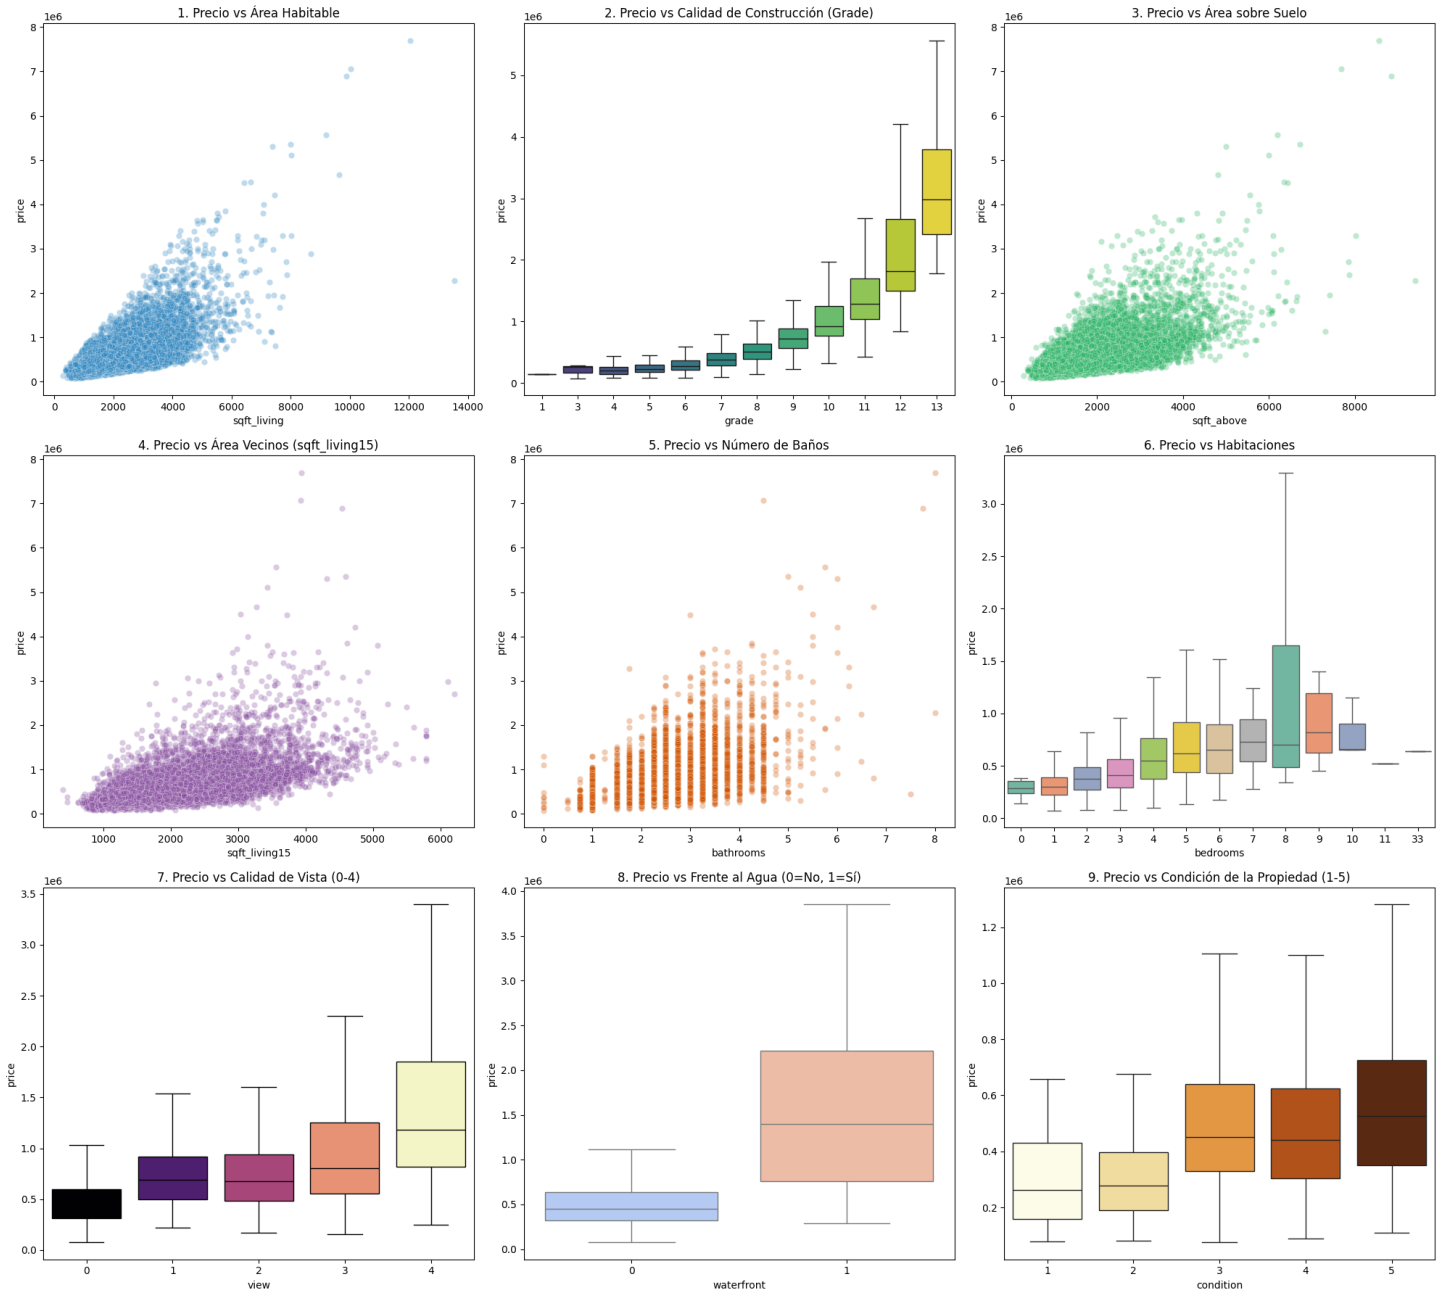

Patrones de Valoración

1. Dominancia y Heterocedasticidad

La relación del área (`sqft_living`) es innegable, pero la varianza del precio aumenta drásticamente en propiedades grandes. Una casa de 4,000 ft^2 puede costar \$1M o \$3M según otros factores.

2. Saltos Bruscos

La calidad y las amenidades premium no crecen linealmente. Pasar de un `grade` 11 al 12, o tener vista al agua (`waterfront`), actúa como un multiplicador, elevando el "piso base" de la propiedad.

3. Rendimientos Decrecientes

Más cuartos no equivale a más valor lineal. Propiedades con 7 u 8 habitaciones se estancan o bajan de precio, sugiriendo que el mercado penaliza distribuciones espaciales ineficientes.

4. Irrelevancia Cosmética

La condición física (`condition`) muestra diferencias mínimas en la mediana. El mercado de King County valora la estructura original y la ubicación por encima del desgaste estético.

Veredicto de Hipótesis Iniciales

Hipótesis Validadas Positivamente

El EDA nos permite confirmar las siguientes premisas:

H1: Efecto del Área Habitable (Confirmada)

Fuerte relación lineal positiva ($r = 0{,}70$) entre `sqft_living` y el precio. Se consolida como el predictor primario.

H4: Amenidades Premium (Confirmada)

Atributos como `waterfront` o una vista excelente elevan drásticamente el valor mínimo de venta, actuando como multiplicadores no lineales.

H6: Influencia del Entorno (Confirmada)

La alta correlación de `sqft_living15` ($r = 0{,}59$) ratifica el "efecto vecindario": propiedades insertadas en zonas de casas grandes ven su valor arrastrado al alza.

Hipótesis Matizadas y Pendientes

H3: Efecto de la Calidad Estructural (Parcial)

Se **confirma** para la calidad de diseño (`grade`), con impacto posiblemente no lineal. Sin embargo, se **refuta** el impacto del mantenimiento cosmético (`condition`, $r = 0{,}04$), el cual es casi nulo.

Hipótesis que requieren (posiblemente) (Modelos No lineales):

H2 y H5: Geografía y Antigüedad

- **Ubicación (`lat`, `long`):** No responden a líneas rectas; exigen modelado espacial mediante clústeres.
- **Antigüedad (`yr_built`):** El mercado valora tanto construcciones ultranuevas como propiedades históricas conservadas. Este comportamiento en forma de "U" requiere otro tipo de análisis.

Otras aproximaciones

Análisis Espacial: El Efecto del Código Postal

Para resolver la Hipótesis 2, salimos de los gráficos tradicionales y observamos cómo se distribuye el valor real sobre el mapa de King County.

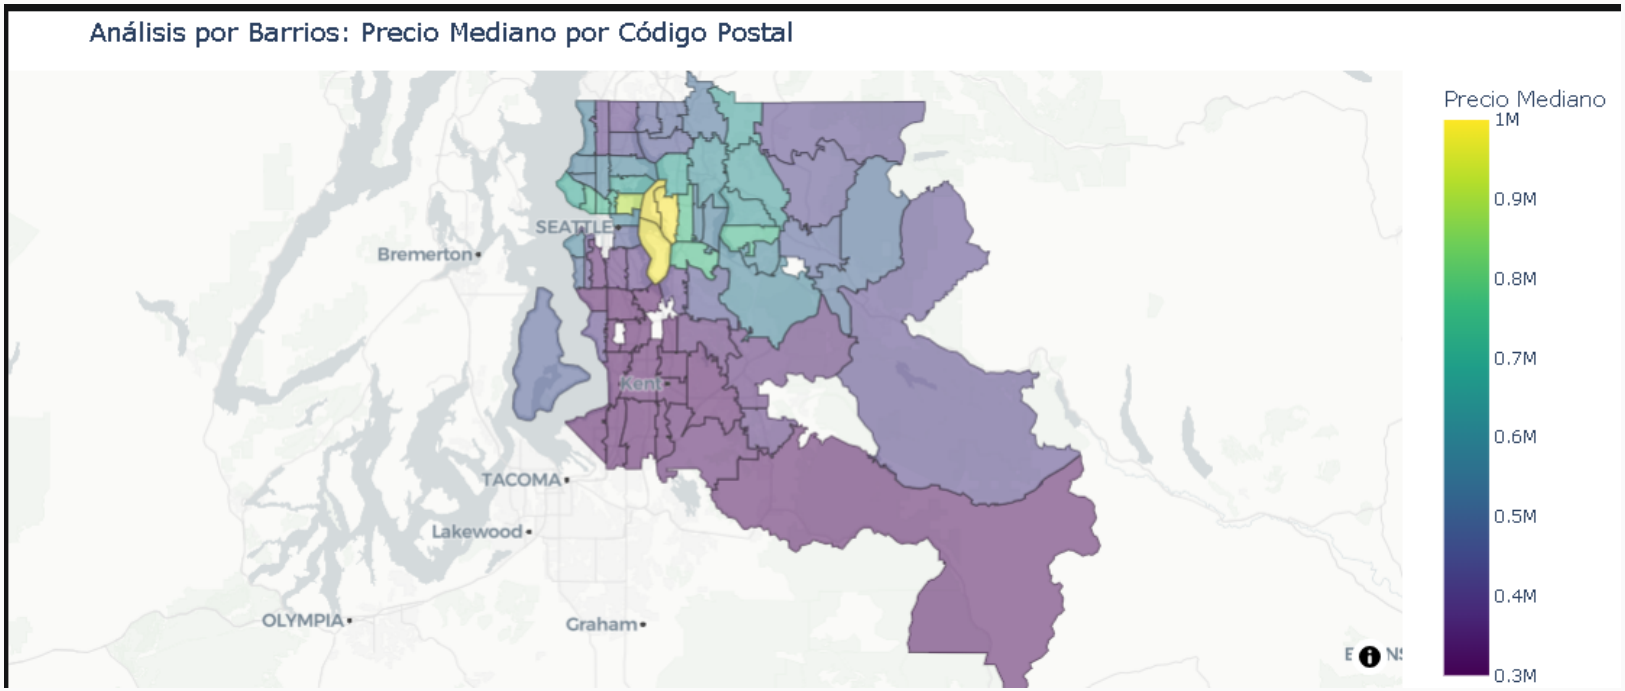

Geografía de Precios (Hipótesis 2)

Visualmente comprobamos que el valor de una propiedad no viaja en línea recta, sino que responde a zonas de influencia o "gravedad.ecónomica.

Puntos Calientes (Hotspots)

El mercado opera por clústeres. Estar cerca de los centros de Seattle/Bellevue o en las riberas del lago crea polos de altísimo valor. A medida que nos alejamos de estos núcleos, el precio decae.

¿Cómo se lo explicamos al modelo?

Como la latitud y longitud puras no forman líneas rectas de precio, un modelo paramétrico se confundiría. La solución en la **Ingeniería de Características** será transformar estas coordenadas en métricas continuas, como calcular la *distancia euclidiana* a estos centros neurálgicos.

Análisis Temporal: Antigüedad vs. Renovación

Para la Hipótesis 5, analizamos qué pasa con el precio a medida que la casa envejece, separando las propiedades originales de las que han sido modernizadas.

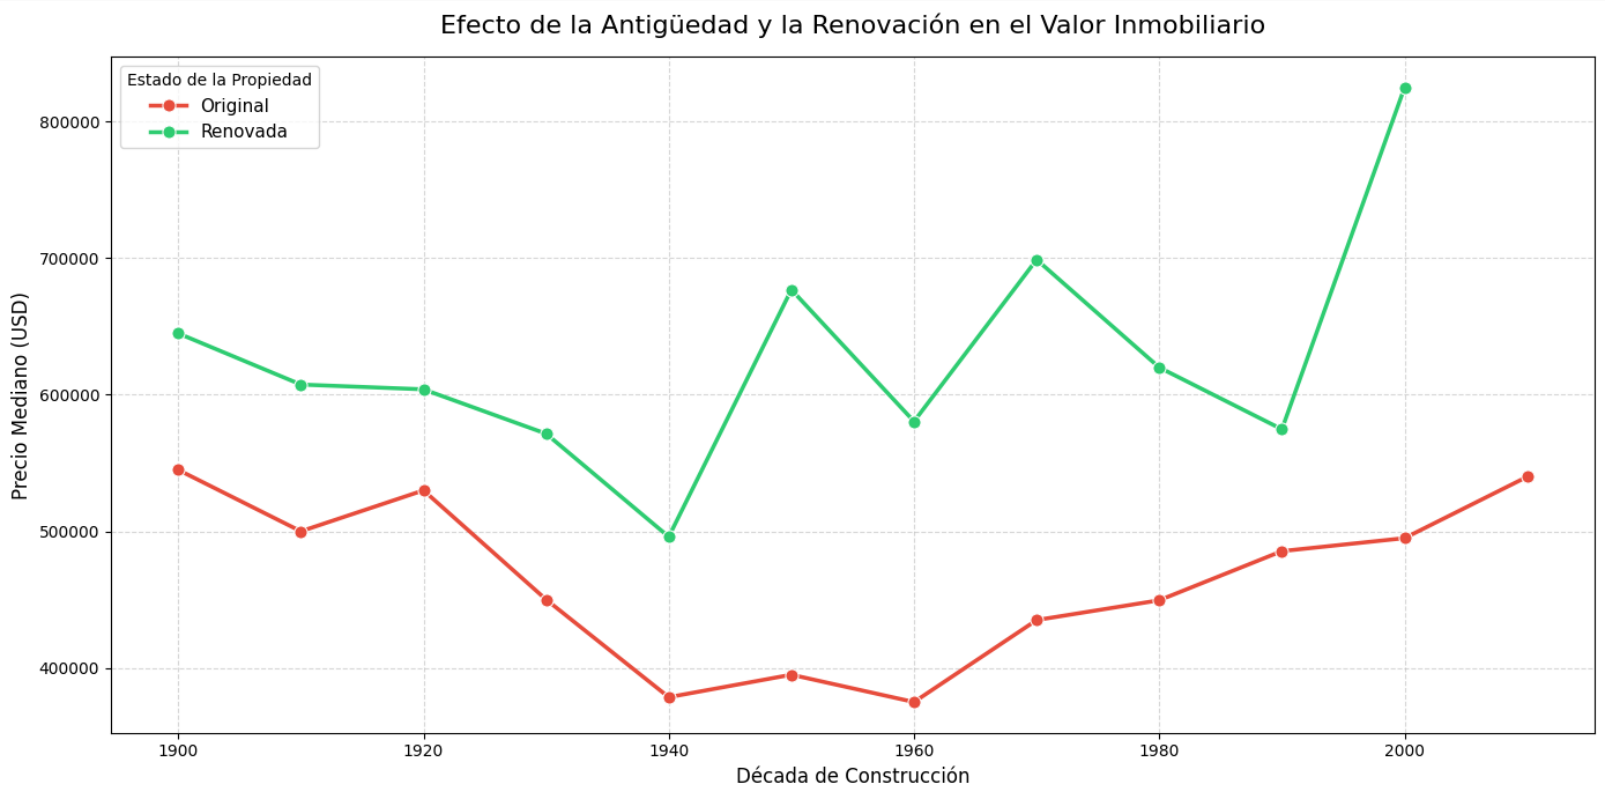

La Renovación (Hipótesis 5)

El factor tiempo nos cuenta una historia fascinante en dos actos: el desgaste natural por los años y el inmenso poder de una buena modernización.

La Curva en forma de "U"

Si miramos las casas originales (línea roja), el precio no cae para siempre. Toca fondo en las construcciones de 1950 a 1970 por obsolescencia de diseño, pero vuelve a subir en propiedades de principios de siglo (1900-1930) gracias a su valor histórico y ubicación céntrica.

El Multiplicador de la Remodelación

La modernización (línea verde) cambia las reglas del juego. Una casa histórica que ha sido renovada por dentro no solo frena su caída, sino que adquiere una "prima de exclusividad", alcanzando precios que superan holgadamente a muchas construcciones de obra nueva.

Tratamiento de Valores Nulos

Simulación de Datos Faltantes

Dado que nuestro *dataset* original está completamente limpio (0 nulos), realizamos una simulación para definir qué método utilizaríamos en producción ante la llegada de datos incompletos.

Metodología: Inyectamos aleatoriamente 1 %, 5 % y 10 % de valores nulos en la variable `sqft_living` y calculamos el Error Medio Absoluto (MAE) al intentar reconstruirlos mediante tres métodos:

- **Mediana:** Imputación estadística básica.
- **KNN (K-Nearest Neighbors):** Imputación basada en similitud con datos cercanos.
- **Imputador Iterativo (MICE):** Imputación mediante regresiones múltiples.

Resultados de la Simulación

Evaluamos el desempeño de cada método según su capacidad para minimizar el error de reconstrucción (MAE):

Escenario	Cant. Nulos	Mediana	KNN	Iterativo (MICE)
1 % de Nulos	20	783.8	393.7	**350.5**
5 % de Nulos	100	790.0	533.9	**370.3**
10 % de Nulos	200	770.2	486.2	**351.7**

Decisión Algorítmica: Imputador Iterativo

El método iterativo logra el menor error en todos los escenarios. A diferencia de la mediana (que ignora el contexto) o KNN (muy costoso computacionalmente), MICE aprovecha las fuertes correlaciones descubiertas previamente (como precio, calidad y baños) para deducir el área faltante con alta precisión.

Pruebas de Hipótesis y Dependencia

Dependencia Numérica: Área vs. Precio

Evaluamos la relación entre `sqft_living` y `price` mediante coeficientes de correlación y sus respectivos niveles de significancia ($\alpha = 0{,}05$).

- **Coeficiente de Pearson (r):** 0.7020 ($p < 0{,}001$).
- **Coeficiente de Spearman (ρ):** 0.6442 ($p < 0{,}001$).

Interpretación

Ambos coeficientes indican una correlación positiva fuerte. El valor de Pearson sugiere una tendencia lineal predominante, mientras que Spearman valida la persistencia de una relación monótona a pesar de la asimetría en la distribución de precios.

Kruskal-Wallis

Dado que la variable `price` no sigue una distribución normal, empleamos la prueba de **Kruskal-Wallis** para evaluar la influencia de la calidad (`grade`) en el valor de mercado.

- **Estadístico** H**:** 9694.85.
- p**-value:** $0{,}00e + 00$.

Conclusión de la Prueba

Con un p-value $< \alpha$, se rechaza la hipótesis nula de independencia. La calidad de diseño y construcción es un determinante significativo en la mediana del precio.

Asociación Categórica y Mutual Information (MI)

Se cuantifica la dependencia entre variables cualitativas y el aporte informativo individual de los predictores respecto al precio.

- **Chi-cuadrado (χ^2):** 7572.56 ($p < 0{,}001$) para la relación `waterfront` vs. `view`.

Variable	Score MI	Variable	Score MI
`sqft_living`	0.3501	`lat` (Latitud)	0.3419
`grade`	0.3495	`bathrooms`	0.1990

Cuadro 6: Ranking de importancia informativa respecto al precio.

Observación Clave

El análisis de MI confirma que la ubicación (`lat`) posee una capacidad informativa equiparable a las dimensiones físicas de la vivienda, capturando dependencias que los coeficientes lineales omiten.

Conclusiones del Análisis Estadístico

La validación mediante pruebas de hipótesis permite concluir:

1. **Significancia:** Todas las relaciones analizadas presentan p-values inferiores a 0.05, descartando la independencia de los factores.
2. **Jerarquía:** El área, la calidad y la latitud se consolidan como los predictores de mayor peso para el modelo.
3. **Estado del Dataset:** Los datos cumplen con la consistencia estadística necesaria para iniciar la fase de regresión múltiple.

¿Preguntas?